

Comparaison de plusieurs moyennes

L'analyse de variance (ANOVA) permet de comparer **les moyennes de plusieurs échantillons**. Les conditions préalables sont :

- les échantillons soient indépendants
- les distributions des mesures étudiées (les échantillons) soient issues de distributions parentes normales: *normalité des données*.
- les échantillons soient extraits de distributions parentes de même variance (les variances observées soient homogènes): *homogénéité des variances*.

Remarque; ces conditions sont identiques à celles du test de Student dans la comparaison de 2 moyennes.

Si l'une de ces hypothèses n'est pas remplie, l'utilisation de l'ANOVA risquerait d'aboutir à des conditions erronées. L'exemple suivant est repris d'un cours consultable sur internet (<http://www.univ-tours.fr/ash/psycho>)

Analyse de variance à 1 facteur:

Supposons que l'on étudie les notes obtenues à une épreuve de math par 4 écoles différentes.

Groupes	A	B	C	D	
Notes	x_{A1} ...	x_{B1} ...	x_{C1} ... x_i ...	x_{D1} ...	
Effectif	n_A	n_B	n_C	n_D	$N = n_A + n_B + n_C + n_D$
Total	T_A	T_B	T_C	T_D	$T_G = T_A + T_B + T_C + T_D$
Moyenne	\bar{x}_A	\bar{x}_B	\bar{x}_C	\bar{x}_D	$\bar{x}_G = T_G / N$

Les trois conditions sont supposées vérifiées :

- « Les écoles sont indépendantes »
- La variable (note en math) se distribue normalement dans les ensembles parents des 4 classes.
- Les ensembles parents des 4 classes ont les mêmes variances.

Les hypothèses statistiques:

(H₀) : moyennes identiques $\mu_A = \mu_B = \mu_C = \mu_D = \mu_G$

(H₁) : Au moins l'une des moyennes est différentes de μ_G

La solution repose sur la décomposition de la variation de la variable en une variation 'intra' groupe et une variation dite 'inter' groupe (variation ou somme des carrés).

La variation totale:

$$SC_T = \sum_{i=1}^N (x_i - \bar{x}_G)^2$$

La variation entre les classes (variation inter-groupe ou factorielle)

$$SC_F = n_A(\bar{x}_A - \bar{x}_G)^2 + \dots + n_D(\bar{x}_D - \bar{x}_G)^2$$

La variation à l'intérieur de chaque classe (variation intra-groupe ou résiduelle)

$$SC_r = \sum_{i=1}^{n_A} (x_{Ai} - \bar{x}_A)^2 + \dots + \sum_{i=1}^{n_D} (x_{Di} - \bar{x}_D)^2$$

On en déduit les variances (ou carrés moyens):

$$CM_T = \frac{SC_T}{N - 1}$$

$$CM_F = \frac{SC_F}{k - 1}$$

$$CM_r = \frac{SC_r}{N - k}$$

Remarques:

$$SM_T = SM_F + SM_r$$

$$ddl_T = ddl_F + ddl_r$$

La statistique de décision:

Le rapport entre la variance inter-groupe et la variance intra-groupe suit une loi de Fisher Snédécour avec les degrés de liberté (ddl Inter, ddl Intra).

$$F = \frac{\text{variance inter}}{\text{variance intra}} = \frac{CM_F}{CM_r}$$

A partir des résultats que l'on observe sur les échantillons, on calcule une valeur de F et on compare cette valeur à une valeur critique (choisie avec un certain seuil, généralement 5% ou 1%).

- Si le f que l'on calcule est inférieur au f critique alors on est dans la zone de non rejet de H_0 , le test est non significatif.
- Par contre si le f calculé est supérieur au f critique alors on est dans la zone de rejet de H_0 . On accepte donc H_1 et on en conclut qu'une moyenne diffère des autres avec le risque d'erreur α . Il y a un effet du facteur étudié.

Source de variation	Somme des carrés des écarts	Nombre de ddl	Carrés moyens (variances)	F
Entre les groupes (inter)	$SC_F = \sum_{j=1}^k \left(\frac{T_j^2}{n_j} \right) - \frac{T_G^2}{N}$	k-1	$CM_F = \frac{SC_F}{k-1}$	$\frac{CM_F}{CM_r}$
A l'intérieur des groupes (intra)	$SC_r = \sum_{i=1}^N x_i^2 - \sum_{j=1}^k \left(\frac{T_j^2}{n_j} \right)$	N-k	$CM_r = \frac{SC_r}{N-k}$	
Total	$SC_T = \sum_{i=1}^N x_i^2 - \frac{T_G^2}{N}$	N-1		

Exemple : On reprend l'exemple précédent avec les notes suivantes

Groupe	A	B	C	D
Notes	6	8	7	4
	3	8	4	3
	7	5	8	6
	5	6	6	3
	4	7	5	
		6	9	
		2		

Supposons que nous ayons vérifié les hypothèses de normalité et d'homogénéité des variances pour les 4 groupes.

Tester l'effet du facteur « écoles » sur les notes obtenues en math.

1/ La méthode utilisée sera bien entendu une méthode d'analyse de variance.
Posez les hypothèses nulle et alternative à tester.

2/ Faites ensuite tous les calculs nécessaires :

Source de variation	Somme des carrés des écarts	Nombre de ddl	Carrés moyens (variances)	F
Entre les groupes (inter)				
A l'intérieur des groupes (intra)				
Total				

F de Snédécour avec 3 et 18 ddl :

$p(F < 3,16) = 0,95$ et $p(F < 5,09) = 0,99$

3/ Conclusion